

Modelli Nascosti di Markov (HMM)

Dalla storia del groupier disonesto alla predizione genica

Motivazione biologica

Il problema

Dato un tratto di DNA:

ATATGCGGCGTATATAGCGCGCGTTATAT

Vogliamo determinare:

- quali regioni sono **esoni**
- quali regioni sono **intron**

Problema:

- osserviamo solo nucleotidi (A,C,G,T)
- non osserviamo direttamente lo “stato funzionale”

L'analogia del groupier disonesto

Due dadi:

- O = dado onesto
- T = dado truccato

Osserviamo:

- solo i numeri usciti

Non osserviamo:

- quale dado viene usato

Domanda:

Possiamo inferire il dado dalla sequenza di numeri?

Elementi fondamentali di un HMM

Un HMM è definito da:

1. **Stati nascosti**
 2. **Osservazioni**
 3. **Probabilità di transizione**
 4. **Probabilità di emissione**
 5. **Distribuzione iniziale**
-

Slide 5 — Traduzione nel problema biologico

Casinò	DNA
Dado onesto	Introne (I)
Dado truccato	Esone (E)
Numero	Nucleotide (A,C,G,T)

Stati nascosti:

- E
- I

Osservazioni:

- A, C, G, T

Modello a due stati (semplice)

Stati

- E = Esone
- I = Introne

Alfabeto osservabile

$\Sigma = \{A, C, G, T\}$

Probabilità di transizione

Esempio semplificato:

Da → A	E	I
E	0.8	0.2
I	0.3	0.7

Interpretazione:

- Gli esoni tendono a essere regioni continue
- Gli introni tendono a essere regioni continue

Probabilità di emissione

Esone (E)

- A: 0.2
- C: 0.3
- G: 0.3
- T: 0.2

(GC-content più alto)

Introne (I)

- A: 0.4
- C: 0.1
- G: 0.1
- T: 0.4

(AT-content più alto)

Struttura grafica del modello

Diagramma concettuale:



Due stati con auto-transizioni dominanti.

Tre problemi fondamentali degli HMM

1. **Valutazione**
P(sequenza | modello)
→ Algoritmo Forward
2. **Decodifica**
Sequenza di stati più probabile
→ Algoritmo di Viterbi
3. **Apprendimento**
Stimare parametri
→ Baum-Welch

Noi oggi ci concentriamo sulla **decodifica**.

Esempio di sequenza

Sequenza osservata:

A T A T G C G G C

Domanda:

Qual è la sequenza più probabile di stati (E/I)?

Intuizione qualitativa

Prime 4 basi:

A T A T → probabile Introne

Ultime basi:

G C G G C → probabile Esone

Quindi ipotesi intuitiva:

I I I I E E E E E

Ma possiamo formalizzarlo?

Idea dell'algoritmo di Viterbi

Per ogni posizione:

- calcoliamo la probabilità massima di arrivare in ciascuno stato
- memorizziamo da dove veniamo

Struttura dinamica:

$$V_k(i) = \max_j [V_{k-1}(j) \times a_{j \rightarrow i}] \times b_i(x_k)$$

Calcolo per le prime due basi

Supponiamo:

$$P(\text{start} \rightarrow E) = 0.5$$

$$P(\text{start} \rightarrow I) = 0.5$$

Per la prima base (A):

$$V1(E) = 0.5 \times P(A|E)$$

$$V1(I) = 0.5 \times P(A|I)$$

Poiché $P(A|I) > P(A|E)$,

→ I è più probabile.

Effetto della transizione

Se restiamo in I:

moltiplichiamo per 0.7

Se passiamo a E:

moltiplichiamo per 0.3

Le transizioni penalizzano cambi troppo frequenti.

Interpretazione biologica

Le transizioni modellano:

- lunghezza media degli esoni
- lunghezza media degli introni

Esempio:

$P(E \rightarrow E)$ alta $\rightarrow$ esoni lunghi in media

Cosa manca rispetto alla realtà?

Modelli reali includono:

- Stati separati per:
 - start codon
 - stop codon
 - siti di splicing
- Modelli a 3 frame
- Dipendenze di ordine superiore

Ma il principio è identico.

Collegamento alla genomica moderna

I gene finder classici (es. GENSCAN):

- sono HMM complessi
- addestrati su genomi annotati

Oggi:

- deep learning
- ma struttura probabilistica simile

Messaggio finale

Un HMM per predizione genica:

È un modello probabilistico che cerca di inferire una struttura funzionale nascosta (esone/introne) osservando solo la sequenza di nucleotidi.

Esattamente come:

inferire quale dado usa il groupier osservando solo i numeri.